Clasificación Multietiqueta de Anomalías de Rodilla en Resonancia Magnética con Supervisión Débil Multilingüe

Salvador Cabrera Taco **Anllelo Carreazo Yrizales** **Yda Ramirez Rojas**
Pedro Alexander Marquez Lamadrid **Mijael Aguirre Zegarra**
Universidad Nacional de Ingeniería (UNI), Lima, Perú
{salvador.cabrera.t, anllelo.carreazo.y, y.ramirez.r,
pedro.marquez.l, mijael.aguirre.z}@uni.pe

Abstract

En el reto RSNA Knee Abnormality Detection solo 58 de 4,407 estudios de RM de rodilla tienen etiquetas verificadas por radiólogos; el resto trae solo el reporte en texto libre, en unos diez idiomas. Un extractor de reglas multilingües con negación, duda y severidad obtiene frente a los dorados un AUC macro de 0.784 y una tasa de ruido de 0.24, mejor que un NLI multilingüe *zero-shot* (0.638). Con esas etiquetas entrenamos sobre 500 estudios un modelo 2.5D con atención por hallazgo. ResNet-50 preentrenada en ImageNet alcanza un AUC macro dorado de 0.658 frente a 0.572 de una CNN propia ($\Delta = -0.087$, IC pareado $[-0.155, -0.016]$). La pérdida focal es la única ablación cuyo IC pareado excluye el cero (AUC 0.698); alta confianza, plano coronal y sobremuestreo de raros mejoran entre $+0.013$ y $+0.033$ sin significancia. Grad-CAM es plausible para contusión ósea y, de forma indirecta, para LCA, pero no para el quiste de Baker. El extractor pierde sensibilidad fuera del inglés y el español, lo que introduce ruido de etiqueta correlacionado con el centro.

1 Motivación

La RM de rodilla es el estudio de referencia para lesiones de ligamentos, meniscos, cartílago y hueso, pero su lectura depende de radiólogos musculoesqueléticos, que son escasos fuera de las grandes ciudades, y tiene variabilidad entre observadores. Un modelo que marque los estudios con hallazgos probables puede ordenar la lista de trabajo y servir de segunda lectura.

El obstáculo práctico no es la arquitectura sino las etiquetas. Los hospitales acumulan miles de estudios con su reporte radiológico, pero casi ninguno con etiquetas estructuradas. El reto RSNA Knee Abnormality Detection (Radiological Society of North America, 2026) refleja esa situación: cada estudio trae su reporte original, en el idioma del centro que lo emitió, y solo 58 estudios tienen las doce etiquetas verificadas por expertos. Por eso el trabajo tiene dos partes: primero convertir el texto clínico en etiquetas (supervisión débil) y medir cuánto ruido introduce, y después entrenar y evaluar el clasificador de imágenes sobre esas etiquetas imperfectas, usando los 58 estudios dorados solo como prueba.

2 Trabajos relacionados

RM de rodilla. Bien et al. (2018) presentaron MRNet: una AlexNet preentrenada procesa cada corte de tres series (sagital, coronal y axial), agrega los cortes con *max pooling* y predice anomalía, rotura de LCA y rotura de menisco; su desempeño fue comparable al de radiólogos generales. Štajduhar

et al. (2017) detectaron lesión de LCA en KneeMRI con descriptores clásicos. Ambos usan etiquetas limpias y pocas clases; aquí hay doce hallazgos y etiquetas ruidosas.

Etiquetas desde reportes. NegEx (Chapman et al., 2001) detecta negaciones con disparadores léxicos antes y después del término clínico; NegBio (Peng et al., 2018) agrega reglas sobre el árbol sintáctico y manejo de incertidumbre. CheXpert (Irvin et al., 2019) usó un etiquetador de reglas con tres estados (positivo, negativo, incierto) para 224 mil radiografías de tórax y comparó varias formas de tratar la incertidumbre en el entrenamiento. Nuestro extractor sigue esa línea, pero es multilingüe y asigna un puntaje ordinal y una confianza por etiqueta. Snorkel (Ratner et al., 2017) combina funciones de etiquetado ruidosas y el aprendizaje confiado (Northcutt et al., 2021) estima qué etiquetas están equivocadas. Como alternativa sin reglas probamos un modelo NLI multilingüe (mDeBERTa-v3 ajustado en XNLI) (Conneau et al., 2018; He et al., 2023).

Arquitectura e interpretabilidad. Usamos ResNet-50 (He et al., 2016) preentrenada en ImageNet (Deng et al., 2009) como codificador por corte y agregamos los cortes con atención, como en el aprendizaje de múltiples instancias de Ilse et al. (2018). Para el desbalance probamos la pérdida focal (Lin et al., 2017), y para interpretar usamos Grad-CAM (Selvaraju et al., 2017). Finalmente, Zech et al. (2018) mostraron que una red de radiografías de tórax aprendía a reconocer el hospital de origen y que su desempeño caía en hospitales externos; ese riesgo es central en un conjunto de 16 centros como este.

3 Datos y reducción de escala

El conjunto completo pesa unos 570 GB (819,640 archivos DICOM). Todo el procesamiento se hizo dentro de un Kaggle Notebook (GPU T4) con los datos montados, sin descargarlos. `train.csv` tiene 4,407 estudios, cada uno con su reporte y las doce columnas `ACL`, `MCL`, `Medial Meniscus`, `Lateral Meniscus`, `Medial OA`, `Lateral OA`, `PF OA`, `Effusion`, `Synovitis`, `Baker's`, `Contusion`, `Fracture`; `train_series.csv` describe 24,371 series con su plano y si son sensibles a líquido. Llamamos *dorados* a los 58 estudios con las doce etiquetas completas.

Detectamos el idioma de cada reporte por vocabulario: inglés (1,740), español (793), turco (546), griego (321), alemán (262), ruso (220), neerlandés (151), francés (75), portugués (42) y 257 sin clasificar (*otro*). La mediana del reporte es de 129 palabras.

Seguimos la reducción de escala recomendada:

- **Plano y secuencia.** Serie sagital sensible a líquido (PD/T2 con supresión grasa), presente en el 94.2 % de los estudios; la serie coronal equivalente (96.4 %) se usa en una ablación.
- **Subconjunto.** De los 3,937 estudios no dorados que tienen ambas series tomamos 500: primero hasta 25 positivos débiles por hallazgo, del más raro al más común, y luego relleno aleatorio. Se dividen en entrenamiento (425) y validación (75), estratificando por el hallazgo positivo más raro.
- **Prueba limpia.** Los dorados con serie sagital (56 de 58) forman el conjunto de prueba. Nunca se usan para elegir épocas, umbrales ni hiperparámetros.

La Tabla 1 muestra la prevalencia de cada hallazgo (Entregable 6). Los dorados tienen muchos más positivos que la muestra débil: sinovitis 44.6 % frente a 13.6 %, fractura 30.4 % frente a 10.6 %. Parte de la diferencia es que el conjunto dorado está enriquecido en casos positivos, y parte es que los reportes no mencionan ciertos hallazgos: la sinovitis aparece en solo el 11.5 % de los reportes.

4 Metodología

4.1 Extracción de etiquetas débiles (Entregable 1)

El extractor principal trabaja con reglas sobre el texto normalizado (minúsculas, sin diacríticos) y separado en cláusulas. Tiene léxicos en diez idiomas (en, es, de, pt, fr, nl, it, tr, el, ru). Distingue dos tipos de hallazgo:

Tabla 1: Prevalencia de los doce hallazgos. "Débil" = etiqueta del extractor sobre los 4,407 estudios; "mención" = fracción de reportes que nombran el hallazgo (positivo o negado). Entrenamiento y validación usan etiquetas débiles; la prueba usa etiquetas doradas. Ordenado por prevalencia en entrenamiento.

Hallazgo	Débil (todos)	Mención	Entren. n (%)	Valid. n (%)	Prueba dorada n (%)
Fractura	6.9	19.5	45 (10.6)	8 (10.7)	17 (30.4)
Artrosis lateral	10.9	36.4	56 (13.2)	10 (13.3)	11 (19.6)
Sinovitis	11.1	11.5	58 (13.6)	12 (16.0)	25 (44.6)
Lig. colateral medial	10.0	49.3	64 (15.1)	10 (13.3)	9 (16.1)
Menisco lateral	14.8	80.7	67 (15.8)	15 (20.0)	23 (41.1)
LCA	15.7	52.2	75 (17.6)	7 (9.3)	23 (41.1)
Artrosis patelofemoral	19.6	41.5	91 (21.4)	16 (21.3)	20 (35.7)
Artrosis medial	16.0	39.3	91 (21.4)	11 (14.7)	15 (26.8)
Quiste de Baker	23.8	36.1	105 (24.7)	20 (26.7)	11 (19.6)
Contusión ósea	20.4	30.7	108 (25.4)	14 (18.7)	18 (32.1)
Menisco medial	30.5	77.4	147 (34.6)	33 (44.0)	24 (42.9)
Derrame	44.0	66.1	206 (48.5)	37 (49.3)	34 (60.7)

- *Autocontenidos* (derrame, sinovitis, Baker, contusión, fractura, artrosis): el término ya nombra el hallazgo. La artrosis se asigna al compartimento (medial, lateral o patelofemoral) nombrado más cerca en la cláusula.

- *Estructura + patología* (LCA, LCM, meniscos): se exige un término anatómico y uno de patología (*rotura, desgarro, tear, Riss, déchirure, yırtık, razryv (ru)*…) a no más de 8 tokens.

Las negaciones siguen la idea de NegEx (Chapman et al., 2001): disparadores previos (*no, sin, kein, pas de, geen, den (el), bez (ru)*) hasta 6 tokens antes, y posteriores (*izlenmedi, nicht nachweisbar, ne vyyavleno (ru), intact*) hasta 5 tokens después, porque en turco, ruso o alemán la negación suele ir detrás del hallazgo. Las expresiones de duda (*posible, fraglich, suspected*) tienen prioridad y los modificadores de severidad modulan el puntaje.

La salida por estudio y hallazgo es un **puntaje ordinal** $s \in [0, 1]$ (negado 0.05, no mencionado 0.15, ambiguo 0.30, dudoso 0.50, leve 0.65, positivo 0.80, moderado 0.85, severo 0.95), una etiqueta binaria $\tilde{y} = \mathbb{1}[s \geq 0.5]$ y una **confianza** c: 1.0 si hay afirmación o negación explícita; 0.6 si no se menciona y el reporte tiene al menos 80 palabras, 0.3 si es más corto (un reporte breve suele listar solo lo patológico, así que el silencio no equivale a ausencia); 0.5 para dudas y 0.4 para casos ambiguos. El puntaje ordinal sirve para medir AUC contra los dorados, porque el AUC solo usa el orden y una salida binaria empata a todos los positivos.

Como método alternativo usamos NLI multilingüe *zero-shot* (mDeBERTa-v3-base ajustado en XNLI, pesos abiertos, ejecutado dentro del notebook, sin enviar reportes a servicios externos) con una hipótesis por hallazgo, y un ensamble por promedio de rangos de ambos métodos. La validación compara cada método con los 58 dorados y reporta AUC, acuerdo, sensibilidad, especificidad, κ de Cohen y la **tasa de ruido** $= 1-$acuerdo, por hallazgo y por idioma.

4.2 Preprocesamiento 2.5D y lateralidad

De cada serie se toman $S = 9$ cortes uniformes del 80 % central, se recorta una ventana física de 150 mm centrada, se normaliza la intensidad por percentiles 0.5–99.5 y se guarda a 256×256 (entrenamiento con recorte aleatorio de 224). Cada corte entra con sus dos vecinos como tres canales (2.5D). Cinco de los doce hallazgos distinguen medial de lateral, así que canonicalizamos la lateralidad: con el tag DICOM `Laterality` cuando existe (43 % de los estudios) o con la coordenada x del centro de la imagen en el sistema LPS. Los cortes sagitales se ordenan de medial a lateral y las series coronales de rodillas derechas se espejan. Por la misma razón **no** usamos volteo horizontal como aumento; usamos recorte, rotación $\pm 10^{\circ}$, escala 0.9–1.1, brillo y contraste.

4.3 Arquitecturas (Entregable 2)

Ambos modelos comparten la misma estructura (Figura 5): un codificador 2D f_θ procesa cada corte y una capa de atención por hallazgo decide qué cortes mirar:

$$h_s = f_\theta(x_{s-1}, x_s, x_{s+1}), \quad a_{\ell,s} = \mathrm{softmax}_s\big(w_\ell^\top \tanh(V h_s)\big), \quad z_\ell = \textstyle\sum_s a_{\ell,s} h_s, \tag{1}$$

y la salida es $\hat{y}_\ell = \sigma(u_\ell^\top z_\ell + b_\ell)$, con $\ell = 1, \ldots, 12$ sigmoides independientes. La atención es la de Ilse et al. (2018), pero con un vector w_ℓ por hallazgo: el menisco medial puede mirar los cortes mediales y el LCA los centrales. Esto da interpretabilidad en dos niveles: qué corte (atención) y dónde dentro del corte (Grad-CAM).

- **A1 — CNN desde cero** (1.91 M parámetros): cinco bloques [conv 3×3–BN–ReLU]$\times 2$ + *max pooling* con 32, 64, 128, 192 y 256 canales, y *global average pooling*.
- **A2 — ResNet-50** preentrenada en ImageNet (23.8 M parámetros), ajuste fino completo con tasa de aprendizaje del codificador igual a 1/10 de la de la cabeza.

El codificador de la ResNet es el único componente preentrenado. El extractor, el preprocesamiento, la CNN A1, la cabeza de atención, las pérdidas y la evaluación son código propio del grupo.

4.4 Pérdida, ruido y desbalance

La pérdida es una BCE (o focal) ponderada por elemento:

$$\mathcal{L} = \frac{\sum_{i,\ell} w_{i\ell}\, \mathrm{BCE}_{p_\ell}(\hat{y}_{i\ell}, \tilde{y}_{i\ell})}{\sum_{i,\ell} w_{i\ell}}, \qquad p_\ell = \mathrm{clip}\Big(\sqrt{(1-\pi_\ell)/\pi_\ell},\, 1,\, 10\Big), \tag{2}$$

donde π_ℓ es la prevalencia débil en entrenamiento y p_ℓ el `pos_weight` (entre 1.03 para derrame y 2.91 para fractura). Por defecto $w_{i\ell} = c_{i\ell}$, la confianza del extractor (peso medio 0.68). La variante focal multiplica cada término por $(1 - p_t)^\gamma$ con $\gamma = 2$ (Lin et al., 2017).

Entrenamiento. AdamW (Loshchilov and Hutter, 2019) (*weight decay* 10^{-4}), *one-cycle*, lote de 6 estudios (54 cortes), precisión mixta. Tasa de aprendizaje: 10^{-3} para la cabeza y 10^{-4} para el codificador en ResNet-50, y 3×10^{-4} para A1. Hasta 12 épocas (15 para A1) con parada temprana a las 4 épocas sin mejora del AUC macro en validación débil; se guarda la mejor época. Cada corrida tomó entre 1.0 y 3.8 minutos en una T4 y la inferencia cuesta 16 ms por estudio.

4.5 Protocolo de evaluación (Entregable 3)

La métrica principal es la oficial del reto: AUC-ROC macro con los doce hallazgos ponderados por igual, sobre los 56 dorados, con IC 95 % por *bootstrap* de estudios (1,000 remuestreos). Para comparar dos modelos usamos *bootstrap* pareado sobre los mismos estudios y reportamos ΔAUC, su IC y $P(\Delta > 0)$.

Para precisión, recall y F1 hace falta un umbral. Elegimos, para cada hallazgo, el umbral que maximiza F1 en la **validación débil**, nunca en los dorados, para que la prueba siga limpia. Preferimos F1 a la exactitud porque con prevalencias de 10–50 % la exactitud premia predecir siempre "negativo"; un despliegue de cribado podría desplazar el umbral hacia más recall. Como referencia también reportamos F1 con umbral fijo de 0.5.

5 Experimentos y resultados

5.1 Calidad de las etiquetas débiles (Entregable 1)

El extractor de reglas obtiene un AUC macro de **0.784** (IC 95 % 0.742–0.823), acuerdo medio de 0.760, **tasa de ruido estimada de 0.240** y κ medio de 0.42 (Tabla 2, Figura 1). El NLI *zero-shot* es mucho peor (AUC 0.638, ruido 0.545): tiende a responder "sí" a casi todo, con sensibilidad 1.0 y especificidad cercana a 0 en las tres artrosis. Sin embargo supera a las reglas justo donde ellas fallan, en sinovitis (0.746 frente a 0.634) y fractura (0.807 frente a 0.777). El ensamble (0.766) no supera a las reglas solas, así que entrenamos con estas.

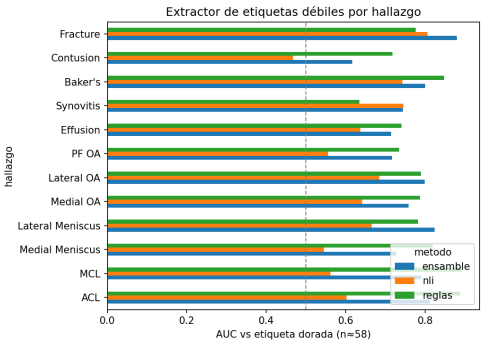


Figura 1: AUC de cada método de etiquetado frente a los dorados ($n = 58$); la línea discontinua marca el azar.

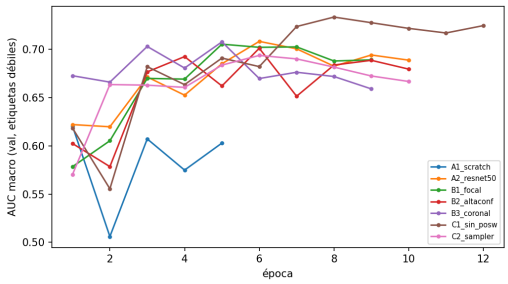


Figura 2: AUC macro en validación débil por época. Las ResNet-50 llegan a su máximo entre las épocas 5 y 8; A1 no mejora después de la primera.

Tabla 2: Extractor de reglas frente a los 58 estudios dorados. Ruido = 1−acuerdo. Las dos últimas columnas dan el AUC de los métodos alternativos.

Hallazgo	Pos.	AUC	Acuerdo	Sens.	Espec.	κ	Ruido	AUC NLI	AUC ens.
LCA	24	0.889	0.845	0.792	0.882	0.678	0.155	0.603	0.813
Lig. col. medial	9	0.892	0.845	0.778	0.857	0.518	0.155	0.562	0.791
Menisco medial	26	0.820	0.724	0.615	0.812	0.434	0.276	0.546	0.728
Menisco lateral	23	0.782	0.741	0.565	0.857	0.439	0.259	0.666	0.825
Artrosis medial	15	0.788	0.810	0.467	0.930	0.445	0.190	0.642	0.758
Artrosis lateral	11	0.789	0.828	0.455	0.915	0.397	0.172	0.685	0.799
Artrosis PF	21	0.735	0.707	0.286	0.946	0.267	0.293	0.557	0.717
Derrame	35	0.740	0.672	0.829	0.435	0.278	0.328	0.637	0.714
Sinovitis	27	0.634	0.655	0.407	0.871	0.287	0.345	0.746	0.744
Quiste de Baker	12	0.848	0.845	0.750	0.870	0.567	0.155	0.743	0.801
Contusión ósea	19	0.719	0.672	0.737	0.641	0.337	0.328	0.468	0.617
Fractura	18	0.777	0.776	0.556	0.875	0.451	0.224	0.807	0.880
Macro		**0.784**	0.760			0.425	**0.240**	0.638	0.766

El error dominante es de **sensibilidad**: la especificidad supera 0.81 en diez de los doce hallazgos, pero la sensibilidad baja a 0.29 en artrosis patelofemoral y a 0.41 en sinovitis. El reporte omite hallazgos que el radiólogo de referencia sí marcó en la imagen. El caso inverso es el derrame (sensibilidad 0.83, especificidad 0.43): los reportes mencionan derrames pequeños o fisiológicos que la etiqueta dorada no cuenta como positivos.

5.2 CNN desde cero frente a transferencia (Entregables 2 y 3)

La Tabla 3 resume las siete corridas y la Figura 3 el AUC por hallazgo. ResNet-50 (A2) alcanza un AUC macro de **0.658** [0.601, 0.716] en los dorados, frente a **0.572** [0.506, 0.630] de la CNN propia (A1). La diferencia pareada es -0.087 con IC $[-0.155, -0.016]$ y $P(\Delta > 0) = 0.013$, así que la ventaja de la transferencia es clara aun con 56 estudios. A1 alcanzó su mejor validación en la primera época y después osciló (Figura 2): con 425 estudios y etiquetas con 24 % de ruido, una red de 1.9 M parámetros sin preentrenar no llega a aprender rasgos anatómicos útiles. Su AUC de artrosis patelofemoral (0.36) y contusión (0.41) queda por debajo del azar, y su atención sobre los cortes es casi uniforme (Sección 5.5). A cambio es tres veces más rápida (1.0 frente a 3.2 minutos).

Para A2, los hallazgos con mejor AUC son LCA (0.77), derrame (0.75), artrosis lateral (0.73) y patelofemoral (0.71). Los peores son fractura (0.49) y menisco medial (0.52). En la fractura confluyen la peor prevalencia de entrenamiento (10.6 %) y una sensibilidad del extractor de 0.56. El menisco medial es el hallazgo más mencionado en los reportes, pero sus lesiones son pequeñas y la serie sagital con 9 cortes puede no capturar el cuerpo del menisco.

Tabla 3: Resultados en el conjunto dorado ($n = 56$). P, R y F1 son promedios macro con el umbral por hallazgo elegido en validación débil. "Época" = mejor época según validación débil. Todas las variantes B y C parten de A2 y cambian un solo factor.

Run	Cambio	Parám.	Época	AUC val	AUC dorado [IC 95 %]	F1	P	R	min
A1	CNN desde cero	1.9 M	1	0.620	0.572 [0.506, 0.630]	0.413	0.389	0.552	1.0
A2	ResNet-50 (base)	23.8 M	6	0.708	0.658 [0.601, 0.716]	0.486	0.472	0.598	3.2
B1	pérdida focal ($\gamma = 2$)	23.8 M	5	0.706	**0.698** [0.645, 0.750]	0.505	0.498	0.588	2.9
B2	solo $c \geq 0.6$	23.8 M	6	0.701	0.687 [0.634, 0.741]	**0.556**	0.488	**0.709**	3.2
B3	plano coronal	23.8 M	5	0.708	0.686 [0.627, 0.743]	0.523	0.475	0.646	2.9
C1	sin pos_weight	23.8 M	8	**0.734**	0.672 [0.614, 0.728]	0.466	0.488	0.522	3.8
C2	sobremuestreo	23.8 M	6	0.694	0.692 [0.642, 0.737]	0.500	0.488	0.596	3.2

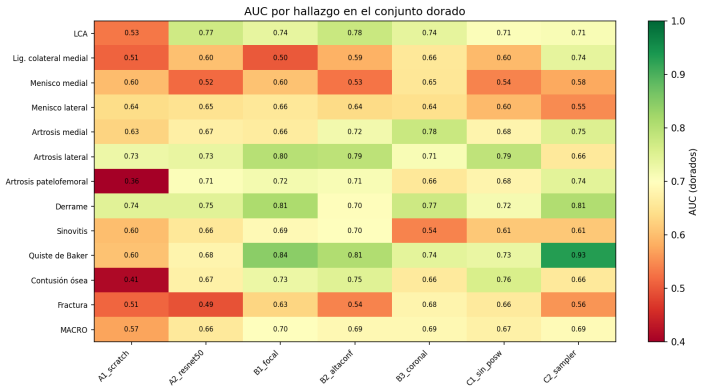


Figura 3: AUC por hallazgo en el conjunto dorado para las siete corridas. La última fila es la métrica oficial (AUC macro).

Precisión, recall y F1. La Tabla 4 desglosa A2. El F1 macro es 0.486 con umbral elegido y 0.478 con umbral 0.5. En A1 la elección del umbral importa mucho más (0.413 frente a 0.184), porque sus probabilidades se agrupan cerca de 0.5. Los umbrales elegidos en validación débil no siempre transfieren bien: en artrosis medial el umbral de 0.87 deja un recall de 0.07, mientras que con 0.5 el F1 sube a 0.52. Hay dos causas. La prevalencia en los dorados es mayor que en la validación débil, y la validación tiene solo 7–37 positivos por hallazgo, así que el máximo de F1 es inestable.

Tabla 4: A2 (ResNet-50) en el conjunto dorado: AUC y P/R/F1 con el umbral por hallazgo elegido en validación débil. La última columna es el F1 de A1 con su propio umbral.

Hallazgo	Pos.	AUC	Umbral	Precisión	Recall	F1	F1@0.5	F1 A1
LCA	23	0.772	0.33	0.563	0.783	0.655	0.681	0.188
Lig. col. medial	9	0.603	0.41	0.227	0.556	0.323	0.286	0.222
Menisco medial	24	0.518	0.16	0.451	0.958	0.613	0.563	0.620
Menisco lateral	23	0.648	0.07	0.514	0.826	0.633	0.359	0.323
Artrosis medial	15	0.670	0.87	0.333	0.067	0.111	0.522	0.414
Artrosis lateral	11	0.733	0.74	0.556	0.455	0.500	0.389	0.364
Artrosis PF	20	0.707	0.71	0.688	0.550	0.611	0.556	0.528
Derrame	34	0.746	0.40	0.673	0.971	0.795	0.785	0.795
Sinovitis	25	0.655	0.75	0.667	0.400	0.500	0.577	0.480
Quiste de Baker	11	0.681	0.49	0.286	0.545	0.375	0.387	0.357
Contusión ósea	18	0.673	0.13	0.327	0.889	0.478	0.524	0.444
Fractura	17	0.495	0.44	0.375	0.176	0.240	0.105	0.222
Macro		**0.658**		0.472	0.598	0.486	0.478	0.413

Tabla 5: Comparaciones pareadas contra A2 sobre los mismos 56 dorados (*bootstrap* pareado, 1,000 remuestreos).

Factor	Comparación	ΔAUC	IC 95 %	$P(\Delta > 0)$	¿Excluye 0?
Arquitectura	A1 (desde cero) vs A2	-0.087	$[-0.155, -0.016]$	0.013	sí (A2 mejor)
Pérdida	B1 focal vs BCE	$+0.040$	$[+0.002, +0.078]$	0.983	sí
Ruido	B2 alta conf. vs ponderar	$+0.028$	$[-0.011, +0.069]$	0.926	no
Plano	B3 coronal vs sagital	$+0.013$	$[-0.047, +0.069]$	0.667	no
Desbalance	C1 sin vs con pos_weight	$+0.014$	$[-0.041, +0.066]$	0.695	no
Desbalance	C2 sobremuestreo vs sin	$+0.033$	$[-0.024, +0.087]$	0.876	no

Tabla 6: AUC en el conjunto dorado de los cuatro hallazgos más raros en entrenamiento.

Hallazgo (prev. entren.)	A2 (`pos_weight`)	C1 (sin)	C2 (sobremuestreo)	B1 (focal)
Fractura (10.6 %)	0.495	0.662	0.558	0.628
Artrosis lateral (13.2 %)	0.733	0.790	0.659	0.800
Sinovitis (13.6 %)	0.656	0.612	0.612	0.689
Lig. colateral medial (15.1 %)	0.603	0.596	0.738	0.501
Media de los 4 raros	0.622	**0.665**	0.642	0.654
AUC macro (12)	0.658	0.672	0.692	**0.698**

Además, la validación débil ordena mal los modelos: C1 tiene el mejor AUC en validación (0.734) y es la quinta de seis ResNet-50 en los dorados. Sirve para detener el entrenamiento, no para elegir entre modelos que difieren en ± 0.03.

5.3 Ablaciones (Entregable 4)

Estudiamos tres factores, cambiando uno a la vez respecto de A2 (Tabla 5), además de la arquitectura (A1 frente a A2):

- **Función de pérdida (B1).** La pérdida focal sube el AUC macro a 0.698 ($\Delta = +0.040$, IC $[+0.002, +0.078]$, $P = 0.98$). Es la única ablación cuyo IC excluye el cero. Las mayores ganancias están en quiste de Baker ($+0.16$), fractura ($+0.13$), derrame ($+0.07$) y artrosis lateral ($+0.07$). La pérdida focal reduce el peso de los ejemplos que el modelo ya clasifica con confianza, y con etiquetas ruidosas también limita cuánto pesan los errores "seguros" del extractor.
- **Manejo de etiquetas ruidosas (B2).** Entrenar solo con etiquetas de confianza ≥ 0.6 (descartando dudas, ambiguos y silencios en reportes cortos) da $+0.028$ ($P = 0.93$, IC con cero) y el mejor F1 macro (0.556, recall 0.709). Ponderar por confianza y filtrar dan resultados parecidos; filtrar es un poco mejor, probablemente porque un peso de 0.3–0.5 sigue empujando hacia "negativo" a hallazgos que el reporte simplemente no menciona.
- **Plano de RM (B3).** El plano coronal da un AUC macro similar ($+0.013$, no significativo), pero cambia *qué* hallazgos se detectan. Mejora los que se ven mejor de frente: ligamento colateral medial (0.60→0.66), artrosis medial (0.67→0.78), menisco medial (0.52→0.65) y fractura (0.49→0.68). Empeora sinovitis (0.66→0.54) y artrosis patelofemoral (0.71→0.66), que se aprecian mejor en el plano sagital. Que los planos sean complementarios indica que fusionar sagital y coronal es la mejora más prometedora.

5.4 Desbalance de clases (Entregable 6)

La prevalencia de entrenamiento va de 10.6 % (fractura) a 48.5 % (derrame) (Tabla 1). Evaluamos tres estrategias, todas sobre ResNet-50: (i) `pos_weight` $= \sqrt{\text{neg}/\text{pos}}$ acotado a $[1, 10]$, la opción por defecto en A2; (ii) quitarlo (C1); y (iii) además del `pos_weight`, sobremuestrear $\times 4$ los estudios con algún positivo del tercio de hallazgos más raros (C2). Ese tercio, según la prevalencia de entrenamiento, es fractura, artrosis lateral, sinovitis y LCM. La Tabla 6 muestra su AUC; incluimos la pérdida focal (B1), que también ataca el desbalance.

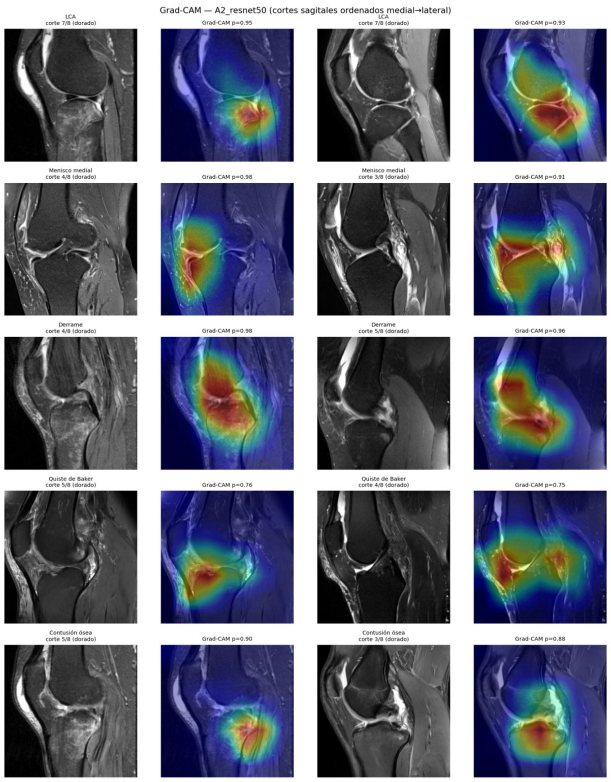


Figura 4: Grad-CAM de A2 (ResNet-50) en dos estudios dorados por hallazgo. El índice de corte va de 0 (medial) a 8 (lateral); p es la probabilidad predicha.

Ninguna estrategia mejora a la vez los cuatro hallazgos raros. El sobremuestreo (C2) da el segundo mejor AUC macro (0.692) y el mayor salto en LCM ($+0.14$), pero sus ganancias más grandes aparecen en hallazgos no tan raros: quiste de Baker llega a 0.931, artrosis medial a 0.753 y patelofemoral a 0.743. Esto se explica porque los estudios sobremuestreados suelen traer varios hallazgos a la vez. Quitar `pos_weight` (C1) no baja el AUC (que no depende de la calibración), pero sí el recall macro, de 0.598 a 0.522: el `pos_weight` desplaza las probabilidades hacia "positivo", que es lo que importa al fijar un umbral de cribado. Con 9 a 25 positivos dorados por hallazgo raro, diferencias de ± 0.05 caben en el ruido de muestreo; la pérdida focal es la mitigación con mejor equilibrio entre AUC macro y hallazgos raros.

5.5 Interpretabilidad: atención y Grad-CAM (Entregable 5)

Para cinco hallazgos (LCA, menisco medial, derrame, quiste de Baker y contusión ósea) tomamos los dos verdaderos positivos dorados con mayor probabilidad, elegimos el corte con mayor atención para ese hallazgo y calculamos Grad-CAM sobre la última capa convolucional (`layer4` en ResNet-50, mapa de 7×7). La Figura 4 muestra A2 y la Figura 5 el perfil de atención.

¿Son anatómicamente plausibles? Los casos se ordenan de más a menos plausible:

- **Contusión ósea: plausible.** El calor se concentra en el hueso subcondral de la meseta tibial y en el cóndilo femoral, donde el edema medular es hiperintenso en secuencias con supresión grasa.
- **LCA: plausible, pero por signos indirectos.** En ambos casos la atención elige el corte 7 (compartimento lateral) y Grad-CAM marca la meseta tibial posterior y la región intercondílea posterior. No resalta las fibras del ligamento en la escotadura, pero sí la zona donde aparece la contusión típica del mecanismo de *pivot shift* que acompaña a la rotura del LCA. El modelo parece reconocer la lesión por su huella ósea, lo cual es útil, pero puede fallar en roturas sin contusión.

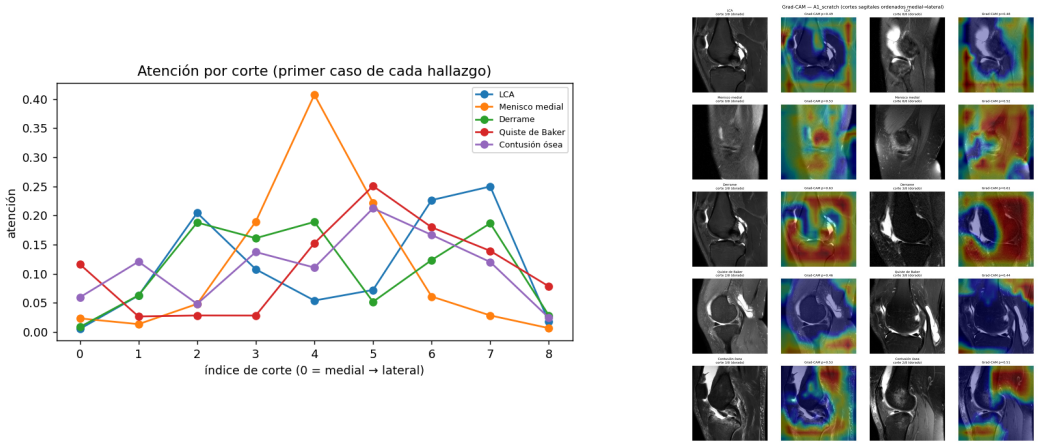


Figura 5: Izquierda: atención de A2 por corte (primer caso de cada hallazgo; 0 = medial). Derecha: Grad-CAM de A1 (CNN desde cero) en casos análogos; los mapas caen en bordes y fondo, no en la anatomía.

- **Menisco medial: parcialmente plausible.** La atención es la más selectiva de todas (pico de 0.41 en el corte 4, Figura 5) y Grad-CAM recorre la interlínea articular con foco en el cuerno anterior. Sin embargo, el corte elegido es central y no uno de los mediales (0–2), donde está el cuerpo del menisco medial. Esto concuerda con su AUC bajo (0.52).
- **Derrame: parcialmente plausible.** Los mapas son difusos y cubren el receso suprapatelar y la articulación. Es razonable para un hallazgo que distiende toda la cápsula, pero el mapa no aísla el líquido.
- **Quiste de Baker: no plausible.** El quiste está en la fosa poplítea posteromedial, pero el mapa se centra en la articulación y la región anterior. Como el quiste suele acompañar al derrame y a la artrosis, lo más probable es que el modelo use esos hallazgos correlacionados como atajo.

CNN desde cero. A1 muestra atención casi uniforme (0.06–0.16, cerca de $1/9$) y probabilidades de 0.44–0.63. Sus mapas Grad-CAM resaltan los bordes de la imagen, el fondo y tejidos blandos lejos de la articulación (Figura 5, derecha): no aprendió rasgos anatómicos. Esto concuerda con su AUC de 0.57 y advierte que un AUC algo mayor que 0.5 puede venir de atajos (tamaño del campo de visión, intensidad del fondo) y no de la anatomía. Dos salvedades valen para todos los mapas: los casos elegidos son los de mayor confianza, y por tanto los más fáciles, y la resolución de 7×7 (unos 32 px por celda) no permite localizar estructuras finas como el menisco.

6 Discusión: riesgo de sesgo geográfico y lingüístico (Entregable 7)

Los estudios vienen de 16 centros en cinco continentes y cada reporte está en el idioma de su centro: 39 % inglés, 18 % español, 12 % turco, 7 % griego, 6 % alemán, 5 % ruso y el resto en otros idiomas. Como el idioma coincide casi uno a uno con la institución, y esta con el fabricante del resonador y el protocolo, **idioma, sitio y equipo están confundidos**. Cualquier diferencia de calidad del extractor entre idiomas produce ruido de etiqueta *correlacionado con el sitio*, no ruido aleatorio.

Lo medimos en los dorados. El acuerdo del extractor es 0.81 en inglés ($n = 28$) y 0.80 en español ($n = 10$), pero baja a 0.75 en turco, 0.67 en ruso, 0.61 en griego y 0.58 en los reportes sin idioma identificado. La **sensibilidad** cae más: 0.78 en inglés, 0.66 en español y 0.64 en turco, frente a 0.42 en griego, 0.08 en ruso y 0.07 en "otro". Con 1–6 estudios por idioma fuera del inglés y el español esto es un indicio, no una estimación, pero la dirección coincide con lo esperable. El léxico es más completo en inglés y español; en ruso, griego y turco la morfología es más rica y la negación suele ir después del término, y además el formato del reporte cambia por centro: unos listan negativos explícitos y otros solo escriben lo patológico en dos o tres líneas.

Consecuencia para el modelo. Si en un centro los positivos quedan sub-etiquetados, la red aprende que las imágenes de ese escáner tienden a ser normales y puede usar atajos (textura, contraste, campo

de visión) que predicen el sitio en vez de la anatomía, como documentaron Zech et al. (2018). El AUC agregado puede verse bien mientras el desempeño en el centro peor etiquetado es malo; los mapas de A1 sobre bordes y fondo muestran que este tipo de atajo es posible.

Implicancias para un despliegue real. Un hospital peruano, con reportes en español y otro equipo y protocolo, sería en la práctica un *sitio nuevo*. Los falsos negativos se concentrarían en hallazgos que los radiólogos suelen omitir en el texto (sinovitis, artrosis leve), justo los peor representados en el entrenamiento. Antes de usarlo haría falta: validación local con etiquetas de imagen hechas por radiólogos del centro; métricas por sitio, idioma y fabricante, no solo el promedio; recalibrar los umbrales; y monitorear el desempeño. En el entrenamiento ayudaría validar agrupando por sitio, revisar el extractor de cada idioma con hablantes nativos o traducir los reportes a un idioma pivote con un modelo local.

7 Limitaciones

Prueba pequeña: con 56 estudios y 9–34 positivos por hallazgo, el IC del AUC macro mide unas ± 0.06 y el de cada hallazgo ± 0.1–0.2; interpretamos direcciones, no décimas. **Etiquetas de reporte frente a etiquetas de imagen:** los reportes omiten hallazgos que los dorados sí marcan, así que la sensibilidad del extractor (0.29–0.83) limita el techo del clasificador. **Sin validación por sitio:** la partición entrenamiento/validación es aleatoria y no sabemos de qué centros vienen los dorados. **Escala reducida:** 500 de unos 3,900 estudios, un plano por modelo, 9 cortes, una semilla por configuración, sin ensambles ni TTA, por el plazo y las horas de GPU. **Interpretabilidad:** Grad-CAM tiene baja resolución y se calculó en casos de alta confianza, así que no prueba que el modelo use siempre las mismas regiones.

8 Conclusiones

Con solo 58 estudios dorados, las reglas multilingües con negación y confianza produjeron etiquetas útiles (AUC 0.784, ruido 0.24), mejores que un modelo NLI genérico. La transferencia desde ImageNet fue necesaria: la CNN propia no aprendió rasgos anatómicos con 425 estudios ruidosos. La pérdida focal fue la única mejora con evidencia estadística (AUC 0.698), y el plano coronal mostró ser complementario al sagital. Los mapas de Grad-CAM son plausibles para contusión y, de forma indirecta, para LCA, pero revelan un atajo para el quiste de Baker. El extractor pierde sensibilidad fuera del inglés y el español, por lo que cualquier uso clínico requiere validación por sitio e idioma. Los siguientes pasos son fusionar planos, usar más estudios débiles, reetiquetar con aprendizaje confiado (Northcutt et al., 2021) y validar agrupando por centro.

Reproducibilidad. El código, el notebook de Kaggle, los registros de cada corrida, las tablas y las figuras están en el repositorio de GitHub del grupo, que se ejecuta de extremo a extremo con `bash 03_scripts/run_all.sh` (ver README y `requirements.txt`). No se versionan DICOM, reportes ni identificadores de estudio.

Referencias

Nicholas Bien, Pranav Rajpurkar, Robyn L. Ball, Jeremy Irvin, Allison Park, Erik Jones, et al. Deep-learning-assisted diagnosis for knee magnetic resonance imaging: Development and retrospective validation of MRNet. *PLoS Medicine*, 15(11):e1002699, 2018. doi: 10.1371/journal.pmed.1002699.

Wendy W. Chapman, Will Bridewell, Paul Hanbury, Gregory F. Cooper, and Bruce G. Buchanan. A simple algorithm for identifying negated findings and diseases in discharge summaries. *Journal of Biomedical Informatics*, 34(5):301–310, 2001. doi: 10.1006/jbin.2001.1029.

Alexis Conneau, Ruty Rinott, Guillaume Lample, Adina Williams, Samuel R. Bowman, Holger Schwenk, et al. XNLI: Evaluating cross-lingual sentence representations. In *Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 2475–2485, 2018.

Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. ImageNet: A large-scale hierarchical image database. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 248–255, 2009.

Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

Pengcheng He, Jianfeng Gao, and Weizhu Chen. DeBERTaV3: Improving DeBERTa using ELECTRA-style pre-training with gradient-disentangled embedding sharing. In *International Conference on Learning Representations (ICLR)*, 2023.

Maximilian Ilse, Jakub M. Tomczak, and Max Welling. Attention-based deep multiple instance learning. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, volume 80 of *PMLR*, pages 2127–2136, 2018.

Jeremy Irvin, Pranav Rajpurkar, Michael Ko, Yifan Yu, Silviana Ciurea-Ilcus, Chris Chute, et al. CheXpert: A large chest radiograph dataset with uncertainty labels and expert comparison. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 33, pages 590–597, 2019. doi: 10.1609/aaai.v33i01.3301590.

Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *IEEE International Conference on Computer Vision (ICCV)*, pages 2980–2988, 2017.

Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.

Curtis G. Northcutt, Lu Jiang, and Isaac L. Chuang. Confident learning: Estimating uncertainty in dataset labels. *Journal of Artificial Intelligence Research*, 70:1373–1411, 2021. doi: 10.1613/jair.1.12125.

Yifan Peng, Xiaosong Wang, Le Lu, Mohammadhadi Bagheri, Ronald Summers, and Zhiyong Lu. NegBio: a high-performance tool for negation and uncertainty detection in radiology reports. In *AMIA Joint Summits on Translational Science Proceedings*, pages 188–196, 2018.

Radiological Society of North America. RSNA knee abnormality detection. Competencia de Kaggle, 2026. URL https://www.kaggle.com/competitions/rsna-knee-abnormality-detection.

Alexander Ratner, Stephen H. Bach, Henry Ehrenberg, Jason Fries, Sen Wu, and Christopher Ré. Snorkel: Rapid training data creation with weak supervision. *Proceedings of the VLDB Endowment*, 11(3):269–282, 2017. doi: 10.14778/3157794.3157797.

Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *IEEE International Conference on Computer Vision (ICCV)*, pages 618–626, 2017.

Ivan Štajduhar, Mihaela Mamula, Damir Miletić, and Gözde Ünal. Semi-automated detection of anterior cruciate ligament injury from MRI. *Computer Methods and Programs in Biomedicine*, 140:151–164, 2017. doi: 10.1016/j.cmpb.2016.12.006.

John R. Zech, Marcus A. Badgeley, Manway Liu, Anthony B. Costa, Joseph J. Titano, and Eric Karl Oermann. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study. *PLoS Medicine*, 15(11):e1002683, 2018. doi: 10.1371/journal.pmed.1002683.